

Universidad de Valladolid

Ampliación de Matemáticas III

Clasificación binaria por mínimos cuadrados

David Vaquerizo Medina

1 Descripción del problema de clasificación

El problema ante el que nos encontramos es: resolver un sistema de ecuaciones sobredeterminado, que cuenta con más ecuaciones que incógnitas. Estos sistemas son, en general, incompatibles: no existe ningún vector que satisfaga exactamente todas las ecuaciones. Para ello se recurre a la resolución en el sentido de mínimos cuadrados, que busca una solución que minimice el residuo (el error cometido), es decir, una solución x^* que minimice el residuo $\|Ax^* - b\|_2$ (véase ec.1), lo que permite definir un hiperplano que clasifica las muestras según su clase.

1.1 Conjunto de datos

Se ha empleado el conjunto de datos *Breast Cancer Wisconsin (Diagnostic)* [1], compuesto de 569 muestras de tumores con 30 características numéricas reales (radio, textura, perímetro, área...) y 2 clases: **maligno** (M) y **benigno** (B).

1.2 Preparación de datos

Para poder trabajar con los datos en MATLAB es necesario primero llevar a cabo una preparación de los datos que consiste principalmente en:

- **Etiquetado.** Las etiquetas (*target*) se recodifican como $b_i \in \{+1, -1\}$ (maligno $\rightarrow +1$, benigno $\rightarrow -1$), de modo que el signo de la predicción determine directamente la clase, simplificando la posterior clasificación como positivo o negativo
- **Partición estratificada.** Se realiza una partición del conjunto de datos mediante `cvpartition` con la opción `HoldOut`, de forma que el 75% de las muestras se emplean para el entrenamiento (≈ 426 muestras) y el 25% de las muestras para el test (≈ 143 muestras). La división es **estratificada**: conserva la proporción original de clases en ambos subconjuntos, garantizando que ninguna clase quede sub o sobre-representada.
- **Normalización.** Cada característica se estandariza mediante la transformación $Z = (X - \mu)/\sigma$, obteniendo así variables aleatorias con media 0 y desviación típica 1. Los parámetros μ y σ se calculan **exclusivamente sobre el conjunto de entrenamiento** y se aplican a ambos conjuntos. Usar los estadísticos del conjunto de prueba para normalizar podría producir el fenómeno conocido como *data leakage*: información futura filtraría al modelo, inflando artificialmente las métricas de rendimiento.

1.3 Regresión multineal y clasificación

Una vez preparados los datos, la estrategia se basa en resolver un problema de regresión multineal. Se construye un separador lineal: un hiperplano $\mathbf{w} \cdot \mathbf{x} + \beta_0 = 0$ en $\mathbb{R}^{30}$ que divida el espacio en dos regiones, una por clase, y que nos va a permitir clasificar las muestras. Para cada muestra de entrenamiento $\mathbf{x}_i \in \mathbb{R}^{30}$ con etiqueta b_i se impone $\mathbf{w} \cdot \mathbf{x}_i + \beta_0 \approx b_i$, lo que da lugar a la regresión multineal de la forma

$$\text{target} \sim A_{\text{train}} \cdot \mathbf{w} + \beta_0. \quad (1)$$

Este sistema es sobredeterminado (426 ecuaciones, 31 incógnitas) y se resuelve en el sentido de mínimos cuadrados, buscando el vector de coeficientes x^* que minimice el residuo $\|A_{\text{train}} x^* - b_{\text{train}}\|_2$. Incorporando β_0 mediante una columna de unos, el sistema a resolver es

$$\begin{pmatrix} a_{11} & \cdots & a_{1,30} & 1 \\ \vdots & \ddots & \vdots & \vdots \\ a_{426,1} & \cdots & a_{426,30} & 1 \end{pmatrix} \begin{pmatrix} w_1 \\ \vdots \\ w_{30} \\ \beta_0 \end{pmatrix} = \begin{pmatrix} b_1 \\ \vdots \\ b_{426} \end{pmatrix}, \quad (2)$$

con $\tilde{A} \in \mathcal{M}_{426 \times 31}(\mathbb{R})$ y $x^* = (w_1, \dots, w_{30}, \beta_0)^T \in \mathbb{R}^{31}$.

En MATLAB, el sistema se resuelve mediante el operador `\`, que internamente aplica factorización QR para

obtener la solución en el sentido de mínimos cuadrados. De forma análoga, se construye la matriz extendida de prueba $\tilde{A}_{\text{test}} \in \mathcal{M}_{143 \times 31}(\mathbb{R})$. Las predicciones sobre el conjunto de prueba se obtienen como

$$\hat{b} = \tilde{A}_{\text{test}} x^*, \quad (3)$$

donde cada componente $\hat{b}_i \in \mathbb{R}$ es el valor predicho para la muestra i . Dado que las etiquetas son $+1$ y -1 , basta con tomar el signo de cada predicción para determinar su clase: $\text{sign}(\hat{b}_i) = +1$ indica tumor maligno y $\text{sign}(\hat{b}_i) = -1$, tumor benigno. La precisión del test, es decir, el porcentaje de aciertos de nuestro modelo se calcula como

$$\text{Precisión} = \frac{\#\{\text{aciertos}\}}{\#\{\text{muestras de prueba}\}} \times 100 \%. \quad (4)$$

Por otro lado, la figura 1 muestra un gráfico de dispersión del conjunto de entrenamiento normalizado, donde se representan dos características, el radio medio frente a los puntos cóncavos medios, coloreando cada muestra según su clase. La elección de estas dos características responde a su elevada capacidad discriminante; como se aprecia en la figura, ambos grupos presentan distribuciones claramente diferenciadas, lo que sugiere que el hiperplano separador será capaz de clasificar correctamente la mayoría de muestras.




Figure 1: Dispersión de muestras de entrenamiento normalizadas (radio medio vs. puntos cóncavos medios) coloreadas por clase. Se aprecia una separación clara entre tumores malignos y benignos, validando la elección de estas características.

2 Resultados y conclusiones

2.1 Precisión del modelo

La tabla 1 recoge las precisiones obtenidas para el modelo completo (30 características) y para el modelo reducido construido con las 5 características de mayor peso absoluto en x^* .

Modelo	Precisión entrenamiento (%)	Precisión test (%)
30 características	96.4871	96.4789
5 características	94.3794	94.3662

Table 1: Precisión de clasificación para los dos modelos evaluados.

2.2 Análisis y conclusiones

Observamos que la precisión de nuestro modelo multilíneal (30 características) es de un 96,4789 %, lo que indica que el modelo se ajusta muy bien a los datos dados pese a las posibles limitaciones derivadas por la elección de un modelo lineal. La regresión multilíneal por mínimos cuadrados asume separabilidad lineal, lo que con datos reales rara vez se cumple de forma exacta, de ahí que el residuo $\|\tilde{A}x^* - b_{\text{train}}\|_2 > 0$. No obstante, una precisión de casi el 97 % evidencia que los datos presentan una estructura suficientemente lineal como para que el modelo sea efectivo. Además, la diferencia de precisión entre el entrenamiento y el test confirma la ausencia de sobreajuste: el modelo no memoriza los datos de entrenamiento sino que captura la estructura real del problema.

Reducción de características. Si analizamos el vector de coeficientes, lo ordenamos y seleccionamos las 5 características que más aportan a dicho vector, estamos identificando las 5 características más determinantes para el modelo; las que más contribuyen en la creación del hiperplano separador. Repitiendo el ajuste solamente con esas 5 características se puede cuantificar en qué medida se concentra la información discriminante en unas pocas características.

El modelo con 5 características retiene el 97.8 % de la precisión del modelo completo (94.37 % frente a 96.48 %), empleando solo 5 de las 30 variables originales. Esto evidencia que la información discriminante se concentra en unas pocas características y que la regresión lineal asigna pesos pequeños al resto, las cuales contribuyen de forma marginal.

References

- [1] W. Wolberg, O. Mangasarian, N. Street, W. Street, *Breast Cancer Wisconsin (Diagnostic) Dataset*, UCI Machine Learning Repository, 1993. <https://doi.org/10.24432/C5DW2B>